

Visualisasi Graf Molekul dan Eksplorasi Properti Kuantum pada Dataset QM9

Menggunakan UI Interaktif berbasis Web

Anggota **Kelompok 4**

Arzha Dwi Ananda A. W.

NIM: 25031554264

M. Pasha Paksi Pasukopati

NIM: 25031554019

M. Habiburrohman Al-Fathir

NIM: 24031554145

Sumber Artikel Ilmiah

Adaptive edge-aware graph convolutional with multi-task learning for simultaneous prediction of material properties

Jurnal: **npj | computational materials**

DOI: <https://doi.org/10.1038/s41524-025-01917-7>

Terindeks Scopus Q1

Diterbitkan: **2026**

Konsep Dasar


Kelompok 4 2025G

Struktur Data dan Algoritma — Sains Data UNESA

Struktur Data Utama: Graph

Material / molekul
direpresentasikan sebagai **Graf**

Graf adalah struktur data yang paling sesuai
untuk menggambarkan **hubungan antar atom**
dalam material.




Komponen Graph

Node (Simpul) = Atom


Contoh: Carbon, Boron

Edge (Sisi) = Ikatan Kimia

Representasi hubungan antar atom dalam struktur.



Visualisasi Node dan Edge



Setiap struktur material (misalnya **Propana** → **C₃H₈**) diubah menjadi satu graf utuh.

Dataset

Kelompok 4 2025G

Struktur Data dan Algoritma — **Sains Data UNESA**

Dataset yang Digunakan

✗ ~~BDG Dataset (Proprietary)~~

✓ **QM9 Dataset** (Open Access)

Data properti molekul organik kecil yang stabil (C, H, O, N, F).

<https://www.tensorflow.org/datasets/catalog/qm9>

Dataset QM9

Metadata Dataset

- Dipilah oleh **Ramakrishnan et al. (2014)**, publikasi *Scientific Data*.
- Bagian dari GDB-17 (~166 miliar molekul organik kecil).
- Molekul dengan **maks. 9 atom berat** (C, N, O, F, dll.).
- Properti kuantum dihitung dengan metode DFT.



Jumlah atom & 16 properti



Koordinat 3D setiap atom



Frekuensi vibrasi



SMILES & InChI Code

Standar emas untuk pemodelan graf molekul dalam kimia komputasi.

Struktur Data Molekul (Mentah)

Data yang dibaca langsung dari file **.xyz**, belum diproses:


```
mol_raw = {  
    'mol_id': 'dft1',  
    'atoms': ['C', 'C', 'O', 'H', ...], # daftar elemen  
    'coords': [[x,y,z], [x,y,z], ...], # koordinat 3D (n×3)  
    'properties': {...}, # 16 properti kuantum  
    'smiles': 'CCO' # string SMILES  
}
```

Belum ada informasi ikatan (*edge*), tata letak 2D, dan nama molekul.

Masalah

Dataset QM9 menyediakan koordinat 3D atom, tetapi tidak menyertakan informasi ikatan (edge)

- Bagaimana membangun graf dari data spasial?
- Bagaimana menyimpan dan menampilkan graf secara efisien?



Pengolahan Data

Kelompok 4 2025G

Struktur Data dan Algoritma — Sains Data UNESA

Langkah Pengolahan Graf

01

Baca data mentah

File `.xyz` → koordinat 3D + properti

02

Inferensi ikatan

Koordinat 3D → *edge* jarak kovalen

03

Bentuk objek graf

Daftar *edge* → graf NetworkX

04

Hitung tata letak 2D

Algoritma *force-directed*

05

Simpan ke cache

Hasil komputasi disimpan ke `Pickle` untuk efisiensi

Pipeline otomatisasi pengolahan data molekul dari format koordinat ke representasi grafis siap pakai.

Konversi Koordinat 3D: Jarak Euclidean

Dataset QM9 menyediakan koordinat 3D tiap atom (x, y, z). Untuk menentukan apakah dua atom berikatan, kita menghitung **jarak Euclidean** antar-keduanya:

$$d_{ij} = \sqrt{(x_i - x_j)^2 + (y_i - y_j)^2 + (z_i - z_j)^2}$$

STRUKTUR DATA

Koordinat disimpan dalam **array** NumPy berukuran **n × 3** untuk efisiensi komputasi.

IMPLEMENTASI

Jarak dihitung menggunakan:
`np.linalg.norm(
 coords[i] - coords[j])`

CAKUPAN

Dilakukan untuk **setiap pasangan atom** sebagai dasar inferensi ikatan.

Transformasi spasial koordinat atom menjadi metrik jarak untuk membangun topologi graf.

Inferensi Ikatan (Edge)

Dua atom dianggap berikatan jika jaraknya kurang dari jumlah jari-jari kovalen + toleransi:

$$d_{ij} < r_i^{\text{cov}} + r_j^{\text{cov}} + \delta$$

Algoritma

Pairwise check:

Periksa semua pasangan atom di sistem.

Implementasi

- Hash map lookup $O(1)$
- Vectorized NumPy calculation

Kompleksitas

Waktu: $O(n^2)$

Ruang: $O(E)$

Delta = 0,45 sebagai toleransi variasi data

Representasi Graf: Adjacency List

Fitur Perbandingan	Adjacency Matrix	Adjacency List
Pengecekan Edge	$O(1)$	$O(\text{degree})$
Memori	$O(n^2)$	$O(V+E)$
Cocok untuk	graf dense	graf sparse

Graf molekul bersifat **sparse** (degree ≈ 2) → **adjacency list lebih tepat**
NetworkX secara internal menggunakan adjacency list untuk efisiensi traversal.

Optimasi struktur data berdasarkan karakteristik sparsity molekul.

Tata Letak 2D: Kamada-Kawai

$$E = \sum_{i < j} k_{ij} (|p_i - p_j| - l_{ij})^2$$

Konsep Sistem Pegas

Memodelkan graf sebagai sistem fisik dimana:

- Panjang ideal l_{ij} sebanding dengan jarak terpendek antar-node.
- Posisi dioptimasi dengan **Newton-Raphson** hingga konvergen.

Karakteristik & Limitasi

Kompleksitas: $O(n^3) + O(n^2)$ per iterasi

Hasil tata letak sangat terstruktur, namun **tidak bisa menangani graf tidak terhubung** secara default.

Algoritma berbasis energi untuk visualisasi molekul yang menyeimbangkan estetika dan jarak geometris.

Tata Letak 2D: Fruchterman-Reingold

$$\frac{d^2}{k}$$

Menarik node yang berikatan

$$-\frac{k^2}{d}$$

Menolak semua node

Mekanisme Simulasi

- Mensimulasikan **gaya tarik** dan **gaya tolak** secara berulang.
- Posisi diperbarui setiap iterasi dengan sistem **cooldown** untuk stabilitas.

Karakteristik & Efisiensi

- Kompleksitas: $O(\text{iter} \times n^2)$
- Kelebihan: **Bisa menangani graf tidak terhubung** secara efektif.
- Digunakan sebagai **fallback** utama sistem.

Algoritma berbasis force-directed yang fleksibel untuk berbagai topologi molekul kompleks.

Strategi Tata Letak

```
if |V| == 1:  
    posisi = (0, 0)  
else:  
    try: posisi = Kamada-Kawai # prioritas: terstruktur  
    except: posisi = Fruchterman-Reingold # fallback
```

Proses normalisasi ke ± 150 piksel dan pemusatan di **origin (0,0)** menjamin konsistensi visual di seluruh sistem.

Hierarki logika pemilihan algoritma untuk menjamin stabilitas visualisasi pada berbagai kondisi topologi graf.

Struktur Data Molekul (Terproses)

Setelah inferensi ikatan, tata letak 2D, dan pencarian nama:

```
mol = {  
  'mol_id': 'dft1',  
  'atoms': ['C', 'C', 'O', 'H', ...],  
  'coords': [[x,y,z], [x,y,z], ...],  
  'bonds': [(0,1,1.54), (1,2,1.43)], # hasil inferensi  
  'pos_2d': {0: (x,y), 1: (x,y), ...}, # hasil tata letak  
  'properties': {...},  
  'smiles': 'CCO',  
  'name': 'Ethanol' # dari PubChem/cache  
}
```

Format ini memudahkan konversi langsung ke objek **PyTorch Geometric Data** atau **NetworkX**.

Optimasi Proses

Kelompok 4 2025G

Struktur Data dan Algoritma — Sains Data UNESA

Penyimpanan Sementara: Pickle

TUJUAN

Menghindari perhitungan ulang $O(n^2 \times 2000)$ setiap startup aplikasi melalui caching data terproses.

- Format **biner Python**, mendukung objek kompleks (graf, array, dict).
- Menyimpan **seluruh dataset**: graf + tata letak + properti.
- Kompleksitas baca/tulis efisien: $O(n)$.
- Lokasi file: `data/qm9_processed/cache.pkl`

Optimalisasi performa startup dengan memigrasikan data berat ke state terserialisasi.

Penyimpanan Sementara: JSON

TUJUAN

Menyimpan pemetaan **SMILES** → Nama **Molekul** secara permanen.

- Format **teks**, mudah dibaca manusia dan kompatibel lintas bahasa.
- Berbentuk **hash map** untuk pencarian cepat.

Contoh Struktur:

```
{"CCO": "Ethanol", "C": "Methane"}
```

- File: `data/qm9_processed/names_cache.json`
- Nama diambil dari **PubChem API**; disimpan agar API hanya dipanggil sekali.

Efisiensi akses data dengan meminimalkan request jaringan ke API eksternal.

Strategi Caching

Tingkat	Format	Isi Data	Kapan Dipakai
1	Pickle (biner)	Seluruh dataset: graf, tata letak, properti	Startup utama
2	JSON (teks)	Pemetaan SMILES → nama molekul	Pencarian nama

Alur Startup Sistem



Hierarki caching untuk menyeimbangkan kecepatan startup dan persistensi data metadata.

Hash Map untuk Pencarian Cepat

Hash Map	Kunci	Nilai	Kegunaan
COVALENT_RADII	Elemen kimia	Jari-jari	Inferensi ikatan
_id_to_idx	mol_id	Indeks array	Pencarian molekul by ID
SMILES_TO_NAME	SMILES	Nama molekul	Pencarian nama
ATOM_COLORS	Elemen kimia	Warna	Visualisasi node

Rantai pencarian: mol_id → **hash map** → indeks → array → data molekul → **total O(1)**

Efisiensi pencarian konstan O(1) menggunakan struktur data dictionary untuk akses data molekuler instan.

Operasi Query & Kompleksitas

Operasi	Struktur Data	Kompleksitas
Daftar molekul (paginasi)	<code>Array</code> (potongan)	$O(\text{limit})$
Cari molekul by ID	<code>Hash map + array</code>	$O(1)$
Bandingkan k molekul	<code>Hash map</code> $\times$ k	$O(k)$
Cari berdasarkan nama	Pencarian berurutan	$O(\text{limit} \times \text{len})$
Statistik properti	Penggabungan <code>array</code>	$O(n)$

`Hash map` membuat operasi terbanyak (pencarian by ID) berjalan dalam waktu konstan $O(1)$

Analisis efisiensi komputasi untuk setiap tipe interaksi data pada sistem manajemen molekul.


Hasil Akhir

Kelompok 4 2025G

Struktur Data dan Algoritma — **Sains Data UNESA**

Hasil Pembentukan Graf

Metrik	Nilai
Molekul berhasil	1 . 996
Total node	~35 . 928
Total edge	~35 . 928
Rata-rata degree	~2 . 0
Graf tidak terhubung	<1 %



Statistik performa algoritma pembentukan graf dari dataset 2.000 file XYZ secara otomatis.

Verifikasi Akurasi

Molekul	V	E Inferensi	E Aktual	Akurasi
Methane (CH ₄)	5	4	4	100%
Ethanol (C ₂ H ₅ OH)	9	8	8	100%
Benzene (C ₆ H ₆)	12	12	12	100%
Acetylene (C ₂ H ₂)	4	3	3	100%

Akurasi 100% dalam mendeteksi keberadaan ikatan, namun sistem saat ini belum membedakan orde ikatan (tunggal/ganda/tiga).

Validasi hasil inferensi ikatan kovalen dibandingkan dengan dataset ground-truth QM9.

Output Proyek

Kelompok 4 2025G

Struktur Data dan Algoritma — Sains Data UNESA

Halaman Awal

 **QM9 Graph Explorer**

Compare

MOLECULE LIBRARY

Search by ID or formula...

Methane

CH4

dsgdb9nsd_000001 · 5 atoms · μ : 0.00 · gap: 0.505

Ammonia

H3N

dsgdb9nsd_000002 · 4 atoms · μ : 1.63 · gap: 0.340

Water

H2O

dsgdb9nsd_000003 · 3 atoms · μ : 1.85 · gap: 0.361

Acetylene

C2H2

dsgdb9nsd_000004 · 4 atoms · μ : 0.00 · gap: 0.335

Hydrogen Cyanide

CHN

dsgdb9nsd_000005 · 3 atoms · μ : 2.89 · gap: 0.380

Formaldehyde

CH2O

dsgdb9nsd_000006 · 4 atoms · μ : 2.11 · gap: 0.226

Ethane

C2H6

dsgdb9nsd_000007 · 6 atoms · μ : 0.00 · gap: 0.335

← Prev

1 / 100

Next →



Select a molecule from the library to explore its graph and properties.

Visualisasi Molekul

 QM9 Graph Explorer

Compare

MOLECULE LIBRARY

Search by ID or formula...

dsgdb9nsd_000009 · 7 atoms · μ : 0.72 · gap: 0.322

C2H3N

dsgdb9nsd_000010 · 6 atoms · μ : 3.83 · gap: 0.364

acetonitrile

dsgdb9nsd_000011 · 7 atoms · μ : 2.57 · gap: 0.234

C2H4O

dsgdb9nsd_000012 · 6 atoms · μ : 3.73 · gap: 0.284

Acetaldehyde

dsgdb9nsd_000013 · 11 atoms · μ : 0.06 · gap: 0.418

Formamide

dsgdb9nsd_000014 · 9 atoms · μ : 1.41 · gap: 0.342

CH3NO

dsgdb9nsd_000015 · 9 atoms · μ : 1.15 · gap:

Propane

dsgdb9nsd_000014 · 9 atoms · μ : 1.41 · gap: 0.342

Ethanol

dsgdb9nsd_000015 · 9 atoms · μ : 1.15 · gap:

Dimethyl Ether

← Prev

1 / 100

Next →


Ethanol

dsgdb9nsd_000014 · C2H6O · 9 atoms · 8 bonds · SMILES: CCO

+ Add to compare

2D GRAPH

Scroll to zoom · Drag to pan



PROPERTIES

Rot. Const A (GHz)	35.0954	Rot. Const B (GHz)	9.3686
--------------------	---------	--------------------	--------

Properti Molekul

 **QM9 Graph Explorer**

0.284

Propane C3H8
dsgdb9nsd_000013 · 11 atoms · μ : 0.06 · gap: 0.418

Ethanol C2H6O
dsgdb9nsd_000014 · 9 atoms · μ : 1.41 · gap: 0.342

Dimethyl Ether C2H6O
dsgdb9nsd_000015 · 9 atoms · μ : 1.15 · gap:

← Prev

1 / 100

Next →

H

H

C

H

Compare

PROPERTIES

Rot. Const A (GHz)	35.0954	Rot. Const B (GHz)	9.3686
Rot. Const C (GHz)	8.1497	Dipole Moment (Debye)	1.4131
Polarizability (Bohr ³)	27.8700	HOMO (Hartree)	-0.2619
LUMO (Hartree)	0.0798	HOMO-LUMO Gap (Hartree)	0.3417
Spatial Extent (Bohr ³)	193.1659	ZPVE (Hartree)	0.0798
U ₀ (Hartree)	-154.9727	U (Hartree)	-154.9684
H (Hartree)	-154.9675	G (Hartree)	-154.9981
Cv (cal/mol-K)	13.5460		

Komparasi Molekul

 QM9 Graph Explorer

Compare **2**

MOLECULE LIBRARY

Search by ID or formula...

ds gdb9nsd_000009 · 7 atoms · μ : 0.72 · gap: 0.322

acet nitrile C2H3N

ds gdb9nsd_000010 · 6 atoms · μ : 3.83 · gap: 0.364

Acetaldehyde C2H4O

ds gdb9nsd_000011 · 7 atoms · μ : 2.57 · gap: 0.234

Formamide CH3NO

ds gdb9nsd_000012 · 6 atoms · μ : 3.73 · gap: 0.284

Propane C3H8

ds gdb9nsd_000013 · 11 atoms · μ : 0.06 · gap: 0.418

Ethanol C2H6O

ds gdb9nsd_000014 · 9 atoms · μ : 1.41 · gap: 0.342

Dimethyl Ether C2H6O


ds gdb9nsd_000015 · 9 atoms · μ : 1.15 · gap: 0.342

← Prev 1 / 100 Next →

Compare Molecules


Ethanol

ds gdb9nsd_000014 · C2H6O · 9 atoms



Propane

ds gdb9nsd_000013 · C3H8 · 11 atoms



Close

SELECTED FOR COMPARE

ds gdb9nsd_000014 ×

ds gdb9nsd_000013 ×

Penutup

Kelompok 4 2025G

Struktur Data dan Algoritma — **Sains Data UNESA**

Kesimpulan

— **Inferensi ikatan** berbasis jarak kovalen berhasil membangun edge dengan **akurasi 100%** pada molekul uji.

— **Tata letak 2D** menggunakan Kamada-Kawai (prioritas) + Fruchterman-Reingold (fallback) yang dinormalisasi.

— **Hash map** menghasilkan rantai pencarian mol_id → data dengan efisiensi waktu konstan **$O(1)$** .

— **Adjacency list** dipilih karena graf bersifat sparse (degree ≈ 2), menghemat memori **$O(V+E)$** vs $O(n^2)$.

— **Konversi 3D→2D**: koordinat 3D hanya untuk inferensi; visualisasi menggunakan posisi 2D force-directed.

— **Caching** (Pickle + JSON) memangkas waktu startup secara signifikan dari **~30 detik** menjadi **~2 detik**.

Terima Kasih

Kelompok 4 2025G

Struktur Data dan Algoritma — Sains Data UNESA